

Research Proposal: metaCAST

一、拟定题目 (Working Titles)

metaCAST: Metadata-based Camera-Agnostic Structured Transfer for Scalable End-to-End Autonomous Driving

- **Metadata-based**: 利用结构化场景数据学习 planning knowledge;
 - **Camera-Agnostic**: 外部训练数据不受 camera intrinsics、extrinsics 和 camera layout 限制;
 - **Structured Transfer**: 将 structured-domain 中学到的规划能力迁移至 image-only policy。
-

二、研究背景与动机 (Motivation)

2.1 Vision-based end-to-end driving 的数据扩展受到 sensor configuration 限制

当前的 vision-based end-to-end autonomous driving 通常直接从多相机图像预测未来 ego trajectory。该范式具有较强的系统简洁性和数据扩展潜力，但其训练数据与具体的 camera rig 高度绑定。

不同自动驾驶数据集通常具有不同的：

- camera 数量与排列方式;
- intrinsics 与 extrinsics;
- field of view 与图像分辨率;
- temporal sampling rate;
- map representation;
- annotation taxonomy;
- trajectory horizon 与 coordinate convention。

[UniDrive](#) 已经表明，视觉模型容易受到 camera configuration 变化的影响，并通过将原始图像映射到统一 virtual camera space 来缓解跨 camera rig 的 perception generalization 问题。该方法仍然需要 source images 和 camera calibration，并主要针对 3D perception，而非跨数据集的 planning knowledge transfer。

因此，简单地将多个数据集的图像直接混合训练，通常需要繁重的 camera normalization、calibration conversion 和 architecture adaptation。[RAP](#) 在联合不同数据域时也需要统一相机顺序、图像分辨率、坐标系和 calibration matrices，说明视觉空间中的 dataset fusion 本身存在较高的几何适配成本。

2.2 大量结构化驾驶数据尚未被 camera-only planner 充分利用

与图像相比，许多公开数据集已经提供较完整的结构化驾驶信息，包括：

- ego and agent trajectories;
- agent class、position、heading、velocity;
- lane graph 与 drivable area;
- traffic-light state;
- local map topology;
- interaction-rich driving scenarios。

例如, [Waymo Open Motion Dataset](#) 提供大规模真实交通交互场景, [Argoverse 2](#) 也重点覆盖复杂运动预测与多城市道路结构。

[ScenarioNet](#) 已经能够将 Waymo、nuScenes、Lyft L5 和 nuPlan 等异构数据转换为统一的 scenario representation; [UniTraj](#) 也证明, 增加数据规模和 domain diversity 可以改善 trajectory prediction 的泛化性能。

然而, 这些工作主要解决:

heterogeneous datasets → unified structured representation → structured prediction/planning

尚未系统解决:

heterogeneous structured datasets → shared planning competence → target-domain camera-or

换言之, 现有 structured-data unification 尚未真正转化为 vision-based end-to-end planner 的数据扩展机制。

2.3 Existing structured-to-visual transfer 仍以单数据集或仿真策略迁移为主

[RAP](#) 将 driving annotations rasterize 成透视视角输入, 利用大量 raster-only samples 训练 planner, 并通过 spatial and global feature alignment 将知识迁移至真实图像。它证明了 lightweight structured rendering 可以支持 planning augmentation, 但 raster representation 仍然与 perspective camera geometry 相关。

[DistillDrive](#) 使用 structured scene planning model 作为 teacher, 为 image-based end-to-end model 提供 planning-oriented supervision; 因此, “structured teacher teaches visual student”本身已不能作为 metaCAST 的主要 novelty。

更近期的 [TerraTransfer](#) 进一步提出将 **learning to drive** 与 **learning to see** 解耦: 先在 vectorized simulator 中通过 self-play 学习策略, 再使用 paired image-scene-state data, 将 policy transfer 至视觉模型。

因此, metaCAST 的核心研究价值不应被表述为普通的 teacher-student distillation, 而应被严格定位为:

利用 camera-configuration-independent canonical scene representation, 将多个异构真实驾驶数据集转化为共享的 planning pretraining corpus, 并将其规划知识迁移至仅使用目标域图像的端到端驾驶模型。

其核心思想是:

Decouple planning-data scaling from sensor-data scaling.

外部数据集负责扩大模型见过的道路结构、交通参与者行为和交互模式; 目标域 image-metadata paired data 只负责解决“如何从目标 camera rig 恢复 planner 所需的信息”。

三、核心问题定义 (Problem Statement)

3.1 Dataset setting

设存在 K 个 heterogeneous driving datasets:

$$\mathcal{D}_k = \{(s_i^k, y_i^k)\}_{i=1}^{N_k}, \quad k = 1, \dots, K,$$

其中:

- s_i^k 表示结构化场景, 包括 map、agent histories、ego state 和可用的 navigation context;
- y_i^k 表示 logged ego future trajectory 或 planning target;
- 不要求数据集 $\mathcal{D}_k$ 提供图像;
- 不要求不同数据集共享相同 camera configuration。

另有目标视觉数据集:

$$\mathcal{D}_T = \{(x_i^T, s_i^T, y_i^T)\}_{i=1}^{N_T},$$

其中 x_i^T 是目标 camera rig 采集的图像, 并与 structured scene s_i^T 配对。

每个数据集拥有不同的数据 schema 和 domain:

$$\Omega_k = (\mathcal{F}_k, \mathcal{C}_k, \Delta t_k, \mathcal{M}_k, \mathcal{Y}_k),$$

分别对应 feature schema、class taxonomy、sampling rate、map representation 和 trajectory definition。

3.2 Learning objective

首先构建 dataset-specific canonicalizer:

$$C_k : s^k \rightarrow z^k,$$

将不同数据集转换至统一的 ego-centric canonical structured space:

$$z^k = \{z_{\text{ego}}, z_{\text{agent}}, z_{\text{map}}, z_{\text{route}}, m_{\text{avail}}\}.$$

其中 m_{avail} 是 attribute availability mask, 用于避免将某数据集缺失的属性错误地解释为零值。

最终目标是学习 image-only policy:

$$\pi_{\text{img}} : (x^T, r^T) \rightarrow \hat{y}^T,$$

使其在目标域上的规划风险最小:

$$\min_{\pi_{\text{img}}} \mathcal{R}_T(\pi_{\text{img}}) = \mathbb{E}_{(x^T, y^T) \sim \mathcal{D}_T} [\ell_{\text{plan}}(\pi_{\text{img}}(x^T), y^T)],$$

同时允许训练阶段利用:

$$\bigcup_{k=1}^K \mathcal{D}_k,$$

但满足部署约束：

$\pi_{\text{img}}^{\text{test}}$ does not access s^T , source images, or source calibrations.

3.3 Research questions

RQ1: Cross-dataset planning transfer

在目标 image data 数量保持不变时，加入来自其他数据集的 structured driving data，能否提高目标 camera-only planner 的性能？

$$\mathcal{R}_T(\pi_{\text{img}}^{\text{multi}}) < \mathcal{R}_T(\pi_{\text{img}}^{\text{target}}).$$

RQ2: Data diversity or merely data volume

性能增益究竟来自数据数量增加，还是来自跨城市、跨道路结构和跨 interaction pattern 的 scenario diversity？

RQ3: Visual data efficiency

multi-dataset structured pretraining 是否可以降低目标域所需的 image-metadata paired data 数量？

即，在 $N'_T \ll N_T$ 时，是否仍能满足：

$$\mathcal{R}_T(\pi_{\text{img}}^{\text{multi}}, N'_T) \leq \mathcal{R}_T(\pi_{\text{img}}^{\text{target}}, N_T)?$$

Central hypothesis

A planner can acquire transferable driving competence from camera-independent structured scenes, while only the visual grounding stage needs to be specialized to the target camera configuration.

四、核心方法 (Methodology: metaCAST)

4.1 Overall architecture

metaCAST 由两个 modality-specific encoders、两个 planner adapters 和一个共享 planner 构成：

$$q_{\text{meta}} = G_{\text{meta}}(E_{\text{meta}}(z)),$$

$$q_{\text{img}} = G_{\text{img}}(B_{\text{vis}}(x)),$$

$$\hat{y} = P(q, r).$$

其中：

- E_{meta} : Canonical Structured Encoder;
- B_{vis} : target-domain visual backbone;
- G_{meta} 、 G_{img} : 将不同 modality 映射到统一 planner query space;
- P : 共享的 planning decoder;
- r : navigation command 或 route context。

系统包含两个主要训练阶段。

Step 1. Canonical Structured Scene Construction

首先对不同数据集定义统一的 canonical scenario schema。

1. Ego-centric spatial normalization

所有 map 与 agent states 被转换至当前 ego coordinate:

$$\tilde{p}_t = R(\theta_{\text{ego}})^{\top} (p_t - p_{\text{ego}}).$$

统一：

- 坐标轴方向;
- 单位;
- heading definition;
- trajectory horizon;
- map range;
- agent-centered versus ego-centered convention。

2. Temporal normalization

将不同采样率的数据重采样至统一时间间隔:

$$\tilde{s}_{t-j} = \text{Interp}(s, t - j\Delta t_{\text{canonical}}).$$

同时显式提供 timestamp 或 time-offset embedding, 避免将插值后的样本误认为原始同步观测。

3. Structured tokenization

将 canonical scene 编码为:

$$Z = [Z_{\text{ego}}; Z_{\text{agents}}; Z_{\text{lanes}}; Z_{\text{crosswalks}}; Z_{\text{lights}}; Z_{\text{route}}].$$

每个 dynamic-agent token 可包含:

$$z_j^{\text{agent}} = [x, y, \cos \theta, \sin \theta, v_x, v_y, a_x, a_y, l, w, c, m_{\text{avail}}].$$

Map elements 使用 polyline tokens 或 vectorized lane tokens 表示。

4. Heterogeneous annotation handling

由于各数据集的 annotation richness 不一致，metaCAST 不强制所有数据拥有完整字段，而是采用：

- attribute availability mask;
- unified coarse taxonomy;
- dataset-specific input adapter;
- optional dataset embedding;
- masked reconstruction 或 masked attention。

这样可以避免 converter 中缺失字段所引入的虚假 supervision。

Representation ablation

核心方法使用 **direct structured tokens**。另设置两种 representation baseline：

1. canonical BEV raster;
2. camera-perspective raster，作为 RAP-style representation。

该设计用于回答：性能提升究竟来自更多数据，还是来自 camera-independent structured representation。

Step 2. Multi-Dataset Structured Planner Pretraining

在所有 structured datasets 上训练 teacher：

$$T_{\text{meta}} = P \circ G_{\text{meta}} \circ E_{\text{meta}}.$$

对于来自数据集 k 的样本：

$$\hat{y}_i^k = P \left(G_{\text{meta}} \left(E_{\text{meta}}(C_k(s_i^k)) \right) \right).$$

训练目标为：

$$\mathcal{L}_{\text{meta}} = \lambda_{\text{traj}} \mathcal{L}_{\text{traj}} + \lambda_{\text{score}} \mathcal{L}_{\text{score}} + \lambda_{\text{safe}} \mathcal{L}_{\text{safe}}.$$

其中：

Trajectory imitation loss

$$\mathcal{L}_{\text{traj}} = \sum_t w_t \text{SmoothL1}(\hat{y}_t, y_t).$$

对于 multi-modal trajectory head，可采用 mode classification 与 best-mode regression。

Planning-aware score supervision

若数据集支持 planner scorer，则进一步学习：

- collision risk;
- drivable-area compliance;
- route progress;
- comfort;

- time-to-collision。

这可以避免 structured planner 仅拟合 logged trajectory，而没有形成 planning-oriented representation。

Dataset-balanced optimization

为防止大型数据集完全主导训练，采用：

$$\mathcal{L}_{\text{multi}} = \sum_{k=1}^K \alpha_k \mathbb{E}_{\mathcal{D}_k} [\mathcal{L}_{\text{meta}}],$$

其中 α_k 可依据数据集规模、scenario rarity 或 validation transfer gain 设定。

训练完成后， P 应学习相对 modality-independent 的 planning function，而 E_{meta} 负责把 canonical structured scene 映射为 planner-consumable queries。

Step 3. Target-Domain Visual Grounding

随后使用目标数据集中的 paired samples：

$$(x_i^T, s_i^T, y_i^T)$$

训练 visual branch：

$$S_{\text{img}} = P \circ G_{\text{img}} \circ B_{\text{vis}}.$$

Structured teacher 生成：

$$q_i^{\text{meta}}, \quad h_{i,l}^{\text{meta}}, \quad p_i^{\text{meta}}(y),$$

visual student 生成：

$$q_i^{\text{img}}, \quad h_{i,l}^{\text{img}}, \quad p_i^{\text{img}}(y).$$

初始阶段冻结：

$$E_{\text{meta}}, G_{\text{meta}}, P,$$

仅优化：

$$B_{\text{vis}}, G_{\text{img}}.$$

这使 visual branch 学习的目标不再是重建所有 metadata，而是产生足以驱动既有 planner 的 representation。

Step 4. Hierarchical Planning-Knowledge Transfer

metaCAST 不仅在单一 feature layer 上进行 alignment，而是在 planner 的多个语义层级迁移知识。

4.1 Planner–query alignment

$$\mathcal{L}_q = \sum_j w_j d(q_j^{\text{img}}, \text{sg}(q_j^{\text{meta}})).$$

其中 d 可采用 normalized Smooth–L1、cosine distance 或 relational distance。

4.2 Planner–state alignment

$$\mathcal{L}_h = \sum_{l \in \mathcal{S}} \beta_l d(h_l^{\text{img}}, \text{sg}(h_l^{\text{meta}})).$$

相比只对齐 encoder feature, planner–state alignment 更直接地约束对决策有用的信息。

4.3 Planning–output distillation

对于 multi–modal trajectory distribution:

$$\mathcal{L}_{\text{out}} = D_{\text{KL}}(p^{\text{meta}}(y) \parallel p^{\text{img}}(y)) + \text{SmoothL1}(\hat{y}^{\text{img}}, \text{sg}(\hat{y}^{\text{meta}})).$$

TerraTransfer 同样采用 action–distribution alignment 与 latent structural alignment, 说明 output–level 和 relation–level supervision 是 state–to–vision policy transfer 的合理基础; metaCAST 的区别在于其 teacher knowledge 来自多个异构真实驾驶数据集, 而非单一 self–play simulator。

4.4 Ground–truth planning loss

$$\mathcal{L}_{\text{GT}} = \mathcal{L}_{\text{plan}}(\hat{y}^{\text{img}}, y^I).$$

总体目标为:

$$\mathcal{L}_{\text{transfer}} = \lambda_q \mathcal{L}_q + \lambda_h \mathcal{L}_h + \lambda_o \mathcal{L}_{\text{out}} + \lambda_g \mathcal{L}_{\text{GT}}.$$

Step 5. Visibility–Aware Distillation

Structured teacher 可能访问 camera 无法观察的对象, 例如:

- 被前车完全遮挡的行人;
- 视野外的 agent;
- annotation 中存在但图像证据不足的交通参与者;
- 比视觉模型更准确的速度和 acceleration。

若强制 visual feature 与完整 structured feature 一致, student 可能被迫学习不可实现的 hallucination。

因此, 为每个 structured element 构建 observability weight:

$$v_j \in [0, 1].$$

局部 query alignment 修改为:

$$\mathcal{L}_q^{\text{vis}} = \sum_j v_j d(q_j^{\text{img}}, q_j^{\text{meta}}).$$

对于不可见信息，不进行直接 token-level imitation，而只保留：

- teacher uncertainty-aware output distillation;
- trajectory-level supervision;
- scene-level relational supervision。

这一区分了：

1. visually recoverable scene knowledge;
2. privileged but non-observable information。

Step 6. Target-Domain Joint Refinement

在 visual grounding 稳定后，可采用低学习率解冻 planner 的上层模块：

$$\theta_P \leftarrow \theta_P - \eta_{\text{small}} \nabla_{\theta_P} \mathcal{L}_{\text{transfer}}.$$

该阶段用于缓解 structured-domain planner 与 image-derived noisy representation 之间的 distribution gap。

训练完成后的部署模型为：

$$\pi_{\text{deploy}} = P \circ G_{\text{img}} \circ B_{\text{vis}},$$

推理阶段不需要：

- GT metadata;
- structured teacher;
- source images;
- source camera calibration;
- rasterizer。

五、实验验证方案（Evaluation Plan）

5.1 Dataset configuration

Primary target: NAVSIM / nuPlan camera domain

[NAVSIM](#) 基于真实驾驶数据构建 scalable planning evaluation，并使用安全、进度与舒适性相关指标评价规划结果。NAVSIM v2 进一步通过 counterfactual observations 评估车辆偏离 logged state 后的 recovery ability。

目标训练数据：

- NAVSIM target-domain images;
- 与图像配对的 nuPlan structured annotations;
- target-domain ego trajectories。

Structured source datasets

建议按以下顺序加入：

- 1. **Additional nuPlan structured-only logs**
用于验证 same-dataset structured scaling。
- 2. **Waymo Open Motion Dataset**
用于增加 interaction-rich US driving scenarios。
- 3. **Argoverse 2 Motion Forecasting Dataset**
用于增加多城市地图结构及长尾交互。
- 4. **nuScenes structured scenes**
用于增加 Singapore/Boston domains，并测试不同 annotation schema。

ScenarioNet 或 UniTraj converters 可作为 canonicalization 的初始工程基础，但需重新定义适合 ego planning 的 route、map 和 target schema。

Secondary benchmark: Bench2Drive

[Bench2Drive](#) 提供 CARLA closed-loop evaluation，包含 44 类交互场景、23 种天气、12 个 towns 和 220 条测试路线，适合验证模型是否真正获得 closed-loop driving competence，而不仅是降低 trajectory error。

5.2 Controlled comparison groups

所有方法应使用相同 visual backbone、planner capacity、target image data 和 optimization budget。

Group	Structured training data	Source images	Transfer mechanism
A. Image-only	None	No	GT trajectory only
B. Target teacher	Target metadata only	No	Structured-to-image distillation
C. In-domain scaling	All nuPlan metadata	No	Same-dataset transfer
D. Cross-dataset, single source	Target + one external dataset	No	metaCAST
E. Cross-dataset, multi-source	Target + multiple external datasets	No	full metaCAST
F. Raster baseline	Rasterized structured data	No	RAP-style R2R alignment
G. Image fusion baseline	Multi-dataset images	Yes	camera/virtual-rig normalization

该分组可以区分：

- teacher distillation 的收益；
- same-dataset extra data 的收益；
- cross-dataset structured knowledge 的额外收益；

- direct tokens 相比 raster representation 的收益；
- camera-free transfer 相比 image-level dataset fusion 的收益。

5.3 Baselines

End-to-end planning baselines

- camera-only target planner；
- iPad or DiffusionDrive camera-only；
- RAP；
- 与 metaCAST 使用相同 backbone 的 target-only implementation。

RAP 应作为最重要的直接对比，因为它已经证明 raster-only augmentation 和 Raster-to-Real alignment 可以改善 NAVSIM v1/v2 performance。

Knowledge-transfer baselines

- target-only structured teacher distillation；
- DistillDrive-style structured teacher；
- query-only alignment；
- output-only distillation；
- TerraTransfer-style action KL + relational structural loss。

Camera normalization baseline

在 source images 可用的子集上，加入 UniDrive-style virtual camera normalization，用于比较：

normalize source images versus discard source images and transfer planning knowledge.

5.4 Main metrics

NAVSIM v1

报告：

- Planning Driving Metric Score, PDMS；
- No At-Fault Collision, NC；
- Drivable Area Compliance, DAC；
- Time-to-Collision, TTC；
- Ego Progress, EP；
- Comfort。

NAVSIM v2

报告：

- two-stage EPDMS；
- Stage-1 performance；

- Stage-2 counterfactual performance;
- collision and recovery-related submetrics;
- Traffic-Light Compliance;
- Driving-Direction Compliance;
- Lane Keeping;
- Extended Comfort。

NAVSIM v2 的 Stage 2 尤其重要，因为它能够检验 external structured data 是否提高了 planner 在偏离 expert trajectory 后的恢复能力，而非仅改善 logged-state imitation。

Bench2Drive

报告：

- Driving Score;
- Success Rate;
- Route Completion;
- Infraction Score;
- Efficiency;
- Comfortness;
- per-scenario-category performance。

Diagnostic metrics

- ADE/FDE 或 MinADE;
- teacher-student output consistency;
- collision rate;
- target-image data efficiency;
- inference latency;
- parameter count;
- source-data preprocessing cost。

5.5 Critical ablation studies

A. Source-data scaling

$$\text{Target} \rightarrow \text{Target} + \text{A} \rightarrow \text{Target} + \text{A} + \text{B} \rightarrow \text{Target} + \text{A} + \text{B} + \text{C}.$$

验证 performance 是否随着 structured scenario diversity 持续增长。

B. Target-image data efficiency

将 target paired image data 设置为：

10%, 25%, 50%, 100%.

核心结果应展示：

multi-dataset metadata teacher 能否让使用较少 target images 的模型达到 target-only full-data baseline。

C. Data volume versus diversity

控制总样本数量，对比：

- 更多 target-domain duplicated/subsampled data；
- 单一 source dataset；
- 多个 source datasets；
- domain-diverse but size-matched data。

只有 multi-domain data 在等量条件下仍有优势，才能证明增益不只是“more samples”。

D. Representation

对比：

- direct metadata tokens；
- canonical BEV raster；
- perspective raster；
- virtual-rig images。

E. Transfer location

分别移除：

- query alignment；
- planner-state alignment；
- output distillation；
- GT trajectory loss；
- visibility-aware weighting。

F. Negative-transfer analysis

进行 leave-one-dataset-out 实验，并按以下属性分组：

- city；
- road topology；
- interaction type；
- agent density；
- weather/time；
- maneuver category。

分析哪些 source domains 对 target planning 有正迁移，哪些会产生负迁移。

5.6 Success criteria

metaCAST 至少应满足以下三个条件，才能支持主要 research claim：

1. 在 target image data 相同的条件下，multi-dataset structured teacher 显著优于 target-only structured teacher；
2. 在 source images 与 source camera calibration 完全不使用的条件下，外部 structured datasets 仍带来稳定收益；
3. 收益在 NAVSIM v2 Stage 2 或 Bench2Drive closed-loop evaluation 中依然成立，而不只是降低 open-loop displacement error。

六、预期贡献 (Expected Contributions)

Contribution 1: New problem formulation

提出 **Camera-Agnostic Cross-Dataset Planning Transfer** 问题，将 autonomous-driving data scaling 分解为：

$$\text{planning-data scaling} \neq \text{sensor-data scaling}.$$

该问题允许来自不同 vehicle platforms、camera rigs，甚至不含图像的数据集，共同为一个 target-domain camera-only policy 提供规划知识。

Contribution 2: metaCAST framework

提出 metaCAST，一种由以下模块组成的统一框架：

- canonical structured scene encoding；
- multi-dataset planner pretraining；
- shared planner interface；
- hierarchical structured-to-visual distillation；
- visibility-aware knowledge transfer。

与 RAP 的 perspective raster transfer 不同，metaCAST 的 source-stage representation 不依赖任何 source camera geometry；与一般 privileged distillation 不同，metaCAST 明确研究跨真实数据集的 planning knowledge aggregation。

Contribution 3: Empirical scaling study

建立系统的 multi-dataset planning transfer evaluation protocol，量化：

- source dataset 数量；
- source scenario diversity；
- target paired-image ratio；
- representation choice；
- cross-dataset domain mismatch；

对最终 camera-only planning performance 的影响。

该研究将回答一个此前尚未被充分验证的问题：

How much can structured driving data from sensor-incompatible datasets contribute to a deployable vision-based planner?

七、潜在风险与降级预案 (Limitations & Mitigations)

Risk 1: Dataset mismatch may cause negative transfer

不同数据集在以下方面存在系统差异：

- traffic rules;
- map semantics;
- vehicle dynamics;
- annotation quality;
- sampling rate;
- route availability;
- logged driver style。

因此，简单混合数据可能导致 teacher 学习相互冲突的 driving behaviors。

Mitigations

1. 使用 dataset-specific canonical adapters 和 availability masks;
2. 采用 dataset-balanced sampling, 避免最大数据集主导训练;
3. 加入 dataset-conditioned normalization 或 lightweight domain adapters;
4. 使用 leave-one-dataset-out validation 估计每个 source domain 的 transfer value;
5. 当 full multi-dataset training 发生负迁移时，降级为：
 - target + selected source datasets;
 - structured pretraining followed by target metadata finetuning;
 - mixture-of-experts structured encoder with shared planner。

Risk 2: Structured teacher possesses information unavailable to cameras

Structured teacher 能够直接访问准确 agent states、遮挡对象和地图属性，而 visual student 受到 occlusion、有限 field of view 和 perception ambiguity 的限制。

若对全部 structured features 进行强制 pointwise alignment, student 可能：

- 学习不可实现的 representation;
- 产生虚假 certainty;
- 过度依赖 teacher 的 privileged information;
- 在真实图像上出现 optimization conflict。

Mitigations

1. 使用 visibility-aware token masking;
2. 将直接 feature imitation 限于 visually observable information;

3. 对不可见信息只使用 uncertainty-weighted output distillation;
4. 保留 GT trajectory supervision, 避免 student 完全复制 teacher error;
5. 将 pointwise feature matching 降级为 relational or planner-output alignment.

若 feature-level alignment 不稳定, 最小可行版本可采用:

$$\mathcal{L} = \lambda_{\text{out}} \mathcal{L}_{\text{out}} + \lambda_{\text{GT}} \mathcal{L}_{\text{GT}},$$

仅迁移 teacher 的 planning distribution, 而不要求 image feature 重建完整 metadata latent.

Proposal Positioning Statement

metaCAST 不应被描述为简单的“metadata fusion”, 也不应将 novelty 建立在“structured teacher can supervise a visual student”之上。

更准确的定位是:

metaCAST is a camera-agnostic planning-data scaling framework that learns a shared planner from canonicalized structured scenes pooled across heterogeneous real-world driving datasets, and transfers the acquired planning competence to a target camera-only policy using paired data exclusively from the target sensor domain.

其最关键、也最需要实验验证的 claim 是:

External driving datasets can improve a target image-only planner even when their images and camera calibrations are never used.

References

1. Li, Y., Zheng, W., Huang, X., & Keutzer, K. UniDrive: Towards Universal Driving Perception Across Camera Configurations. ICLR 2025. <https://arxiv.org/abs/2410.13864>
2. Li, Q., et al. ScenarioNet: Open-Source Platform for Large-Scale Traffic Scenario Simulation and Modeling. NeurIPS 2023 Datasets and Benchmarks. <https://arxiv.org/abs/2306.12241>
3. Feng, L., et al. UniTraj: A Unified Framework for Scalable Vehicle Trajectory Prediction. ECCV 2024. <https://arxiv.org/abs/2403.15098>
4. Feng, L., et al. RAP: 3D Rasterization Augmented End-to-End Planning. <https://arxiv.org/abs/2510.04333>
5. Yu, R., et al. DistillDrive: End-to-End Multi-Mode Autonomous Driving Distillation by Isomorphic Hetero-Source Planning Model. <https://arxiv.org/abs/2508.05402>
6. Xiong, Z., et al. TerraTransfer: Learning End-to-End Driving Policies Without Expert Demonstrations. <https://arxiv.org/abs/2606.17386>
7. Dauner, D., et al. NAVSIM: Data-Driven Non-Reactive Autonomous Vehicle Simulation and Benchmarking. NeurIPS 2024. <https://arxiv.org/abs/2406.15349>

8. Jia, X., et al. **Bench2Drive: Towards Multi-Ability Benchmarking of Closed-Loop End-to-End Autonomous Driving.** NeurIPS 2024 Datasets and Benchmarks. <https://arxiv.org/abs/2406.03877>
9. Ettinger, S., et al. **Large Scale Interactive Motion Forecasting for Autonomous Driving: The Waymo Open Motion Dataset.** ICCV 2021. <https://arxiv.org/abs/2104.10133>
10. Wilson, B., et al. **Argoverse 2: Next Generation Datasets for Self-Driving Perception and Forecasting.** NeurIPS 2021 Datasets and Benchmarks. <https://arxiv.org/abs/2301.00493>