

metaCAST — 首次讨论版

Metadata-based Camera-Agnostic Structured Transfer for Scalable End-to-End Autonomous Driving

本次讨论目标：先对齐 metaCAST 的 **problem formulation**、**system principle** 与 **validation logic**。具体数据集、scene representation 和 transfer loss 留待后续 survey 与实验决定。

1. Problem — 我们究竟要解决什么问题？

1.1 核心研究问题

视觉端到端驾驶的数据扩展通常与 camera rig 绑定；不同数据集的相机数量、内外参、视场角和时序配置不同，直接复用 source images 需要额外的 sensor normalization。

metaCAST 尝试绕开这一依赖：

Can external driving datasets improve a target image-only planner even when their images and camera calibrations are never used?

换言之，核心主张不是统一所有 source sensors，而是：

Decouple planning-data scaling from sensor-data scaling.

外部数据集用 camera-independent structured scenes 扩大 planner 接触到的道路结构、交通行为与交互模式；只有目标域 paired data 负责把这些 competence grounding 到目标 camera rig。

1.2 问题设定

- Source structured datasets: $\mathcal{D}_k = \{(s_i^k, y_i^k)\}_{i=1}^{N_k}$ ，不要求提供图像或共享 camera configuration。
- Target paired dataset: $\mathcal{D}_T = \{(x_i^T, s_i^T, y_i^T)\}_{i=1}^{N_T}$ 。
- 训练阶段可使用 $\bigcup_k \mathcal{D}_k$ ；部署时 policy 只访问 target images 与必要的 route command：

$$\pi_{\text{img}} : (x^T, r^T) \rightarrow \hat{y}^T, \quad \pi_{\text{img}}^{\text{test}} \text{ does not access } s^T, \text{ source images, or source calibrations.}$$

1.3 Novelty boundary

- [UniDrive](#) 统一不同 camera configurations 下的视觉观测，仍使用 source images/calibration，主要面向 perception generalization。
- [ScenarioNet](#) 已统一异构 structured scenario schema，因此 canonicalization 只能作为 infrastructure。
- [RAP](#) 的 source raster 不使用真实图像，但 representation 仍与 perspective geometry 相关。
- [DistillDrive](#) / [TerraTransfer](#) 已建立 structured/state policy 到 visual policy 的迁移，故 teacher-student transfer 本身也不是 novelty。

metaCAST 不是凭 canonicalization 或 distillation 单个组件主张 novelty，而是提出并验证 camera-agnostic, cross-dataset planning-data scaling 这一研究问题。

2. Principle — 系统应如何分工？

2.1 核心 decomposition

当前假设是把 learning to drive 与 learning to see 分开：

$$\begin{aligned} z = C_k(s^k) &\xrightarrow{E_{\text{meta}}, G_{\text{meta}}} q_{\text{meta}} \xrightarrow{P} \hat{y}, \\ x^T &\xrightarrow{B_{\text{vis}}, G_{\text{img}}} q_{\text{img}} \xrightarrow{P} \hat{y}. \end{aligned}$$

- C_k ：把各数据集转换为 ego-centric canonical structured scene z ；
- E_{meta} ：从 structured scenes 学习场景与交互表示；
- P ：预期成为 camera-agnostic、可复用的 shared planner；
- B_{vis} ：只针对 target camera rig 学习 visual perception/grounding；
- q ：两个模态与 planner 之间的 planner-facing interface。

这一 decomposition 需要在讨论中确认。若真正共享的只是 planning behavior，方法不必强制共用 decoder；若 shared planner 是核心，后续架构与实验必须围绕它设计。

2.2 最小训练流程

Stage A — Structured planning pretraining

$$\bigcup_k \mathcal{D}_k \xrightarrow[\text{no source images/calibration}]{\text{canonical structured scenes}} E_{\text{meta}} + G_{\text{meta}} + P.$$

目标是验证跨数据集 structured training 是否形成可迁移至 target domain 的 planning competence。

Stage B — Target visual grounding

只使用 $\mathcal{D}_T$ 中的 paired images 与 structured scenes，使视觉分支接入同一 planner。MVP 从最弱假设开始：

$$\mathcal{L}_{\text{MVP}} = \lambda_{\text{GT}} \mathcal{L}_{\text{GT}} + \lambda_{\text{out}} \mathcal{L}_{\text{out}}.$$

仅当 output-level transfer 不足时，再考虑 planner-query / relational alignment、metadata noise/dropout、visibility-aware transfer 或 joint refinement；这些只是候选 engineering mechanisms。

2.3 当前保留的两个关键风险

1. **Planning semantics mismatch**：统一 schema 不等于统一 planning task。若 source data 缺少 route/command，logged ego future 可能更接近 behavior prediction，而非条件化 planning。
2. **Privileged-information mismatch**：structured teacher 可能使用 camera 看不到的精确状态或遮挡目标，导致 visual student 无法复现 teacher representation。

两者都需在 survey 与 MVP 中审计，但本次不展开具体 dataset 或 loss。

3. Evidence — 什么结果才说明方向成立？

3.1 两个因果 checkpoint

Checkpoint A: planning knowledge 能否跨数据集积累？

在相同 architecture、训练预算和 target evaluation 下比较：

target-only structured planner vs. target + external structured-data planner.

若后者没有稳定提升，应先检查 planning compatibility、canonicalization 与 negative transfer，而非增加 visual transfer 机制。

Checkpoint B: 这种优势能否保留到 image-only policy？

固定相同 target images、visual architecture、grounding procedure 与计算预算：

target-only teacher → visual student A,
multi-dataset teacher → visual student B.

只有 student B 在 target-domain planning evaluation 中稳定优于 student A，才能直接支持核心主张。最终证据应来自 planning-aware / closed-loop evaluation；open-loop error 只用于调试。

3.2 首次讨论只聚焦三个问题

1. Problem formulation

After rereading UniDrive, I understand the goal as using sensor-incompatible structured datasets to scale planning knowledge, rather than normalizing their images. **Is this the central problem you originally had in mind?**

2. System principle

I assume the planner is the reusable camera-agnostic component, while the target visual encoder learns its interface. **Is this separation essential, or do you imagine the two branches being trained more jointly?**

3. Validation logic

I propose testing cross-dataset structured transfer first, then whether the gain survives visual grounding under the same target images. **Does this two-checkpoint logic provide the right evidence?**

3.3 希望本次讨论得到的结论

- 确认 metaCAST 的主问题是否是 **camera-agnostic planning-data scaling**；
- 确认 shared planner + target-specific visual grounding 是否是必要的系统原则；
- 确认是否接受 **structured transfer → image-only transfer** 的两阶段验证逻辑。

在这三个 high-level 判断对齐后，再独立完成 source-dataset audit、representation survey，并定义第一个 go/no-go experiment。